

Московский авиационный институт
(национальный исследовательский университет)

Факультет информационных технологий и прикладной
математики

Кафедра вычислительной математики и программирования

Лабораторная работа №4 по курсу «Криптография»

Студент: А. В. Тимофеев
Преподаватель: А. В. Борисов
Группа: М8О-307Б-19
Дата:
Оценка:
Подпись:

Москва, 2022

Лабораторная №4

Задача:

- Сравнить: 1) два осмысленных текста на естественном языке,
2) осмысленный текст и текст из случайных букв,
3) осмысленный текст и текст из случайных слов,
4) два текста из случайных букв,
5) два текста из случайных слов.

Как сравнивать:

Считать процент совпадения букв в сравниваемых текстах – получить дробное значение от 0 до 1 как результат деления количества совпадений на общее число букв. Расписать подробно в отчёте алгоритм сравнения и приложить сравниваемые тексты в отчёте хотя бы для одного запуска по всем пяти подпунктам. Осознать какие значения получаются в этих пяти подпунктах. Привести свои соображения о том почему так происходит.

Длина сравниваемых текстов должна совпадать. Привести соображения о том какой длины текста должно быть достаточно для корректного сравнения.

1 Описание

В качестве текста на осмысленном языке я выбрал поэму В.В. Маяковского "Облако в штанах". Ее я разбил на два осмысленных текста по 7040 знаков для сравнения в программе.

Далее я составил словарь из слов поэмы и алфавит из букв поэмы. В алфавит я включил все русские буквы кроме "ё" а также включил пробел, получилось 33 символа. Из словаря я составил тексты длиной 7040 знаков из разных слов, а из алфавита я составил тексты, длина слова в которых была случайной, от 1 до длины алфавита, длина этих текстов тоже составила 7040 знаков. Все тексты, используемые в данной лабораторной работе написаны на русском языке.

Алгоритм сравнение достаточно прост. Подаются два текста для сравнения, далее из каждого текста берется i -ый элемент и сравниваются друг с другом. Если элемент совпадают, то увеличиваем счётчик совпавших символов на 1. Сравнение регистрозависимое.

2 Исходный код

```
1 import random
2
3 def split_words(a_text):
4     cur_word = ''
5     prev_is_alpha = False
6
7     for letter in a_text:
8         if letter.isdigit():
9             continue
10        if (letter.isalpha() and prev_is_alpha):
11            cur_word += letter
12        elif (letter.isalpha() and not prev_is_alpha):
13            if cur_word: yield cur_word
14            cur_word = letter
15            prev_is_alpha = not prev_is_alpha
16        else:
17            if cur_word: yield cur_word
18            cur_word = ''
19            prev_is_alpha = False
20        if cur_word: yield cur_word
21
22 def generate_random_chars(alphabet, lenght):
23     ans = ""
24     max_idx = len(alphabet) - 1
25     for _ in range(lenght):
26         ans += alphabet[random.randint(0, max_idx)]
27     return ans
28
29 def generate_random_words(base, lenght):
30     gen_len = 0
31     ans = ""
32     while gen_len < lenght:
33         possible_words = list(filter(lambda x: len(x) <= lenght - gen_len, base))
34         idx = random.randint(0, len(possible_words)-1)
35         ans += possible_words[idx]
36         gen_len += len(possible_words[idx])
37         if gen_len < lenght:
38             ans += " "
39             gen_len += 1
40     return ans
41
42 def compare_texts(text1, text2):
43     if len(text1) != len(text2):
44         raise ValueError
45     lenght = len(text1)
46     equals = 0
47     for i in range(lenght):
```

```

48         if text1[i] == text2[i]:
49             equals += 1
50     return equals / lenght
51
52 def clean_dict(old_dict):
53     new_dict = set()
54     for symbol in old_dict:
55         if((symbol >= 'а' and symbol <= 'я') or symbol == ' '):
56             new_dict.add(symbol)
57     return new_dict
58
59 if __name__ == '__main__':
60     filepath = "D:\\education\\education\\Cripta\\lab4\\resource\\oblako.txt"
61     random.seed(42)
62     oblako = ""
63     with open(filepath, 'r', encoding='utf-8') as txt:
64         oblako = txt.read()
65     oblako_words = list(map(lambda x: x.lower(), split_words(oblako)))
66     print(oblako_words[:15])
67     oblako_text = " ".join(oblako_words)
68     print(oblako_text[:100])
69     print("\n Осмысленные тексты: \n")
70     text_len = len(oblako_text) // 2
71     human_text1 = oblako_text[:text_len]
72     print("Длина полученного текста №1:", len(human_text1))
73     with open("D:\\education\\education\\Cripta\\lab4\\resource\\human1.txt", 'w') as f:
74         f.write(human_text1)
75     human_text2 = oblako_text[text_len:2 * text_len]
76     print("Длина полученного текста №2:", len(human_text2))
77     with open("D:\\education\\education\\Cripta\\lab4\\resource\\human2.txt", 'w') as f:
78         f.write(human_text2)
79     print("\n Тексты сгенерированные по словам: \n")
80     old_alphabet = list(set(oblako_text))
81     alphabet = list(clean_dict(old_alphabet))
82     print("Длина алфавита:", len(alphabet))
83     chars_text1 = generate_random_chars(alphabet, text_len)
84     print("Длина сгенерированного текста №1:", len(chars_text1))
85     with open("D:\\education\\education\\Cripta\\lab4\\resource\\chars1.txt", 'w') as f:
86         f.write(chars_text1)
87     chars_text2 = generate_random_chars(alphabet, text_len)
88     print("Длина сгенерированного текста №2:", len(chars_text2))
89     with open("D:\\education\\education\\Cripta\\lab4\\resource\\chars2.txt", 'w') as f:
90         f.write(chars_text2)
91     word_base = list(set(oblako_words))
92     print("\n Тексты сгенерированные по буквам: \n")

```

```

93 words_text1 = generate_random_words(word_base, text_len)
94 print("Длина сгенерированного текста №1:", len(words_text1))
95 with open("D:\\education\\education\\Cripta\\lab4\\resource\\words1.txt", 'w') as f
96     :
97     f.write(words_text1)
98 words_text2 = generate_random_words(word_base, text_len)
99 print("Длина сгенерированного текста №2:", len(words_text2))
100 with open("D:\\education\\education\\Cripta\\lab4\\resource\\words2.txt", 'w') as f
101     :
102     f.write(words_text2)
103 ans = compare_texts(human_text1, human_text2)
104 print(f"\n Доля совпадений в словах осмысленных текстов: {ans * 100:.2f}% \n")
105 mean = 0
106 ans = compare_texts(human_text1, chars_text1)
107 mean += ans
108 print(f"Доля совпадений в словах осмысленного текста №1 и сгенерированного из
109     букв текста №1: {ans * 100:.2f}%")
110 ans = compare_texts(human_text1, chars_text2)
111 mean += ans
112 print(f"Доля совпадений в словах осмысленного текста №1 и сгенерированного из букв
113     текста №2: {ans * 100:.2f}%")
114 ans = compare_texts(human_text2, chars_text1)
115 mean += ans
116 print(f"Доля совпадений в словах осмысленного текста №2 и сгенерированного из букв
117     текста №1: {ans * 100:.2f}%")
118 ans = compare_texts(human_text2, chars_text2)
119 mean += ans
120 print(f"Доля совпадений в словах осмысленного текста №2 и сгенерированного из
121     букв текста №2: {ans * 100:.2f}%")
122 print(f"Средняя доля совпадений в словах: {(mean / 4) * 100:.2f}% \n")
123 mean = 0
124 ans = compare_texts(human_text1, words_text1)
125 mean += ans
126 print(f"Доля совпадений в словах осмысленного текста №1 и сгенерированного из слов
127     текста №1: {ans * 100:.2f}%")
128 ans = compare_texts(human_text1, words_text2)
129 mean += ans
130 print(f"Доля совпадений в словах осмысленного текста №1 и сгенерированного из
131     слов текста №2: {ans * 100:.2f}%")
132 ans = compare_texts(human_text2, words_text1)
133 mean += ans
134 print(f"Доля совпадений в словах осмысленного текста №2 и сгенерированного из слов
135     текста №1: {ans * 100:.2f}%")
136 ans = compare_texts(human_text2, words_text2)
137 mean += ans
138 print(f"Доля совпадений в словах осмысленного текста №2 и сгенерированного из слов
139     текста №2: {ans * 100:.2f}%")
140 print(f"Средняя доля совпадений в словах: {(mean / 4) * 100:.2f}% \n")
141 ans = compare_texts(chars_text1, chars_text2)

```

```
132 | print(f"Доля совпадений в словах сгенерированного из букв текста №1 и  
    | сгенерированного из букв текста №2: {ans * 100:.2f}%")  
133 | ans = compare_texts(words_text1, words_text2)  
134 | print(f"Доля совпадений в словах сгенерированного из слов текста №1 и  
    | сгенерированного из слов текста №2: {ans * 100:.2f}%")
```

3 Консоль

Судя по результатам, выведенным программой, наилучшие совпадения получаются, если сравнить два осмысленных текста и два текста, созданных из случайных слов, а на третьем месте результат сравнения осмысленного текста и сгенерированного из случайных слов текста .

Доля совпадений в словах осмысленных текстов: 6.34%

Средняя доля совпадений в словах осмысленного текста и сгенерированного из букв текста: 2.99%

Средняя доля совпадений в словах осмысленного текста и сгенерированного из слов текста: 5.68%

Доля совпадений в словах текстов, сгенерированных из случайных букв: 3.29%

Доля совпадений в словах текстов, сгенерированных из случайных слов: 5.78%

Осмысленные тексты:

Длина полученного текста №1: 7030

Длина полученного текста №2: 7030

Тексты сгенерированные по словам:

Длина алфавита: 33

Длина сгенерированного текста №1: 7030

Длина сгенерированного текста №2: 7030

Тексты сгенерированные по буквам:

Длина сгенерированного текста №1: 7030

Длина сгенерированного текста №2: 7030

Доля совпадений в словах осмысленных текстов: 6.34%

Доля совпадений в словах осмысленного текста №1 и сгенерированного из букв текста №1: 2.92%

Доля совпадений в словах осмысленного текста №1 и сгенерированного из букв текста №2: 3.09%

Доля совпадений в словах осмысленного текста №2 и сгенерированного из букв текста №1: 3.09%

Доля совпадений в словах осмысленного текста №2 и сгенерированного из букв текста №2: 2.89%

Средняя доля совпадений в словах: 2.99%

Доля совпадений в словах осмысленного текста №1 и сгенерированного из слов текста №1: 5.73%

Доля совпадений в словах осмысленного текста №1 и сгенерированного из слов текста №2: 5.70%

Доля совпадений в словах осмысленного текста №2 и сгенерированного из слов текста №1: 5.46%

Доля совпадений в словах осмысленного текста №2 и сгенерированного из слов текста №2: 5.83%

Средняя доля совпадений в словах: 5.68%

Доля совпадений в словах сгенерированного из букв текста №1 и сгенерированного из букв текста №2: 3.29%

Доля совпадений в словах сгенерированного из слов текста №1 и сгенерированного из слов текста №2: 5.78%

4 Выводы

Выполнив четвертую лабораторную работу по курсу «Криптография», я провел интересную исследовательскую работу.

Результаты данной работы были ожидаемы, наилучшие совпадения получаются, если сравнить два осмысленных текста и два текста, созданных из случайных слов, на третьем месте результат сравнения осмысленного текста и сгенерированного из случайных слов текста, на четвертом результат сравнения двух текстов, одного из случайных слов, а другого из случайных букв, и на пятом месте результат сравнения осмысленного текста и текста из случайных букв.

Полученные данные можно объяснить тем, что в осмысленных текстах есть правила построения предложений, какое слово за каким следуют, так как в русском языке эти правила дают некую свободу в расположении слов, результат сравнения осмысленных текстов наверно меньше, чем если бы мы использовали английскую грамматику и алфавит. Так же можно заметить, что количество знаков в алфавите, сгенерированном с помощью выбранного мною текста равно 33 знаков, что больше, чем в латинском алфавите.

Меня удивило, что разница в процентах между совпадениями двух осмысленных текстов и двух текстов, созданных из случайных слов, получилась небольшая, наверно это по упомянутой выше причине (о большей свободе в грамматике чем в английском).

В заключении могу сказать, что сложно установить длину текста, для которой сравнения будут считаться корректными, но мне кажется текст должен быть длиннее 1000 символов.